

گزارش تمرین سوم: مدل سازی واژه و طبقه بندی خبر

محمد طاها مجلسی
شماره دانشجویی: ۸۱۰۱۰۱۵۰۴

۱۵/۱۰/۱۴۰۲

فهرست مطالب

۳	۱	مقدمه
۳	۱.۱	اهداف دقیق تمرین
۳	۲.۱	سوالات تحقیق
۳	۳.۱	پروتکل بازتولیدپذیری
۴	۲	سوال اول: پیاده سازی CBOW و Skip-Gram
۴	۱.۲	بارگذاری داده
۴	۲.۲	پیش پردازش
۵	۱.۲.۲	نمونه های آموزشی
۷	۲.۲.۲	آمار واژگان و نمونه ها
۷	۳.۲.۲	کلمات پرتکرار
۷	۴.۲.۲	نمودار کلمات
۸	۳.۲	پیاده سازی شبکه و آموزش شبکه
۸	۱.۳.۲	مدل CBOW
۸	۲.۳.۲	مدل Skip-Gram
۹	۳.۳.۲	فرمول بندی ریاضی
۹	۴.۳.۲	پیکربندی آموزش
۱۰	۵.۳.۲	نتایج آموزش
۱۰	۶.۳.۲	تحلیل بهره وری اجرایی
۱۰	۴.۲	مقایسه مدل ها
۱۰	۱.۴.۲	تحلیل پیچیدگی محاسباتی
۱۱	۲.۴.۲	تفسیر روند همگرایی
۱۱	۳.۴.۲	جمع بندی فنی سوال اول
۱۱	۴.۴.۲	تحلیل شباهت واژگان
۱۲	۳	سوال دوم: پیاده سازی طبقه بند اخبار با کمک شبکه عصبی
۱۲	۱.۳	بارگذاری داده و پیش پردازش
۱۲	۱.۱.۳	نمونه هایی از داده ها
۱۲	۲.۱.۳	دلیل نیاز کمتر به پیش پردازش در FastText
۱۳	۲.۳	تولید بازنمایی جمله
۱۳	۱.۲.۳	آمار طول متن ها

۱۳	۲.۲.۳	خط لوله‌ی کامل سوال دوم
۱۴	۳.۲.۳	فرمول‌بندی مسئله‌ی طبقه‌بندی
۱۴	۴.۲.۳	دلایل طراحی معماری MLP
۱۴	۳.۳	پیاپی‌سازی شبکه و آموزش شبکه
۱۵	۱.۳.۳	پیکربندی آموزش
۱۵	۲.۳.۳	نتایج آموزش
۱۵	۴.۳	تحلیل نتایج
۱۶	۱.۴.۳	ماتریس درهم‌ریختگی
۱۶	۲.۴.۳	تفسیر کمی ماتریس درهم‌ریختگی
۱۶	۳.۴.۳	پایداری معیارهای ارزیابی
۱۶	۴.۴.۳	بهترین و بدترین عملکرد
۱۷	۵.۴.۳	اشتباهات رایج
۱۷	۶.۴.۳	نمونه‌های اشتباه
۱۷	۷.۴.۳	تحلیل طول متن و دقت
۱۷	۴	محدودیت‌ها و تهدیدهای اعتبار
۱۷	۱.۴	محدودیت‌های فنی
۱۷	۲.۴	تهدیدهای اعتبار تجربی
۱۸	۳.۴	اقدام‌های پیشنهادی برای کاهش محدودیت‌ها
۱۸	۵	راهنمای اجرای بازتولید
۱۸	۱.۵	اجرای یک‌دست پاییلین
۱۸	۲.۵	خروجی‌های مورد انتظار
۱۸	۳.۵	چک‌لیست صحت اجرا
۱۸	۴.۵	معیارهای کنترل کیفیت خروجی
۱۹	۶	پاسخ مستقیم به سوالات تحقیق
۱۹	۱.۶	پرسش ۱: همگرایی Word2Vec
۱۹	۲.۶	پرسش ۲: مقایسه‌ی CBO و Skip-Gram
۱۹	۳.۶	پرسش ۳: کفایت FastText+MLP برای AG News
۱۹	۴.۶	پرسش ۴: الگوهای خطا و راهکار کاهش آن
۱۹	۷	نتیجه‌گیری
۱۹	۱.۷	دستاوردهای کلیدی
۱۹	۲.۷	آموزش‌های آموخته شده
۲۰	۳.۷	پیشنهادهای برای بهبود
۲۰	۴.۷	مسیرهای توسعه‌ی آینده
۲۰	۸	پیوست: مشخصات اجرای آزمایش
۲۰	۱.۸	نرم‌افزار و وابستگی‌ها
۲۰	۲.۸	ساختار مصنوعات نهایی
۲۰	۳.۸	نکته‌ی عملی برای اجرای مجدد

۱ مقدمه

این گزارش به ارائه‌ی یک پیاده‌سازی انتها-به-انتها و تحلیل دقیق دو مسئله‌ی کلیدی در پردازش زبان طبیعی می‌پردازد. در بخش نخست، مدل‌های Word2Vec شامل CBOW و Skip-Gram از پایه توسعه داده شده‌اند تا رفتار یادگیری بازنمایی واژه به صورت شفاف بررسی شود. در بخش دوم، یک سامانه‌ی طبقه‌بندی خبر با بهره‌گیری از FastText و یک شبکه‌ی عصبی چندلایه پیاده‌سازی و ارزیابی شده است.

۱.۱ اهداف دقیق تمرین

این تمرین با سه هدف محوری طراحی شده است:

- پیاده‌سازی الگوریتم‌های کلاسیک Word2Vec از صفر برای درک سازوکار یادگیری embedding
- مقایسه‌ی کمی و کیفی دو رویکرد CBOW و Skip-Gram بر داده‌ی واقعی
- طراحی یک خط لوله‌ی طبقه‌بندی متن با استفاده از embedding‌های پیش‌آموزش دیده

۲.۱ سوالات تحقیق

برای ساختاردهی به تحلیل تجربی، مطالعه بر پایه‌ی پرسش‌های زیر پیش رفته است:

۱. آیا پیاده‌سازی Word2Vec از صفر روی WikiText به همگرایی پایدار می‌رسد؟
۲. تفاوت CBOW و Skip-Gram از نظر هزینه‌ی محاسباتی و کیفیت شباهت معنایی چیست؟
۳. آیا بازنمایی جمله بر پایه‌ی FastText برای طبقه‌بندی AG News با یک MLP چندلایه کافی است؟
۴. الگوهای خطای اصلی مدل طبقه‌بندی کدامند و چه راهکارهایی برای کاهش آن‌ها وجود دارد؟

۳.۱ پروتکل بازتولیدپذیری

برای تضمین قابلیت بازتولید نتایج، اصول زیر در کل فرایند رعایت شده‌اند:

- تنظیم بذر تصادفی برای random، numpy و torch
- اجرای نوت‌بوک از کرنل تمیز با اسکریپت خودکار
- ذخیره‌ی شکل‌های گزارش در مسیر ثابت report/
- مدیریت دانلود مدل FastText به صورت idempotent و قابل ازسرگیری

سیاست بازتولید	مولفه
data/ داخل مخزن scripts/execute_notebook.py scripts/run_pipeline.sh report/top_words.png, report/wordcloud.png XeLaTeX در دو پاس	مسیر داده‌ها اجرای نوت‌بوک اجرای کامل پایپلاین خروجی نمودارها کامپایل گزارش

جدول ۱: چک‌لیست بازتولید نتایج و مصنوعات اجرایی

۲ سوال اول: پیاده‌سازی CBOW و Skip-Gram

۱.۲ بارگذاری داده

برای این بخش از دیتاست -WikiText^۲ استفاده شده است که شامل متن‌های ویکی‌پدیا است. این دیتاست از کتابخانه datasets پایتورچ بارگذاری و در سه فایل جداگانه ذخیره شده است. آمار دیتاست به شرح زیر است:

- مجموعه آموزشی: ۷۱۸،۳۶ خط، ۵۴۰،۰۸۸،۲ کلمه، ۲۷۸،۳۳ کلمه منحصر به فرد
- مجموعه اعتبارسنجی: ۷۶۰،۳ خط، ۶۴۶،۲۱۷ کلمه، ۶۲۷،۱۳ کلمه منحصر به فرد
- مجموعه آزمون: ۳۴۶،۴ خط، ۰۱۹،۲۴۶ کلمه، ۵۳۵،۱۴ کلمه منحصر به فرد

```
"txetikiw" = EMAN_TESATAD | ۱
"1v-war-2-txetikiw" = GIFNOC_TESATAD | ۲
"2-txetikiw/atad" = RID_EVAS | ۳
]"tset" , "noitadilav" , "niart"[ = STILPS | ۴
| ۵
)"...tesatad_ GIFNOC_TESATAD{gnidaol"f(tnirp | ۶
)GIFNOC_TESATAD , EMAN_TESATAD(tesatad_daol = stesatad_war | ۷
| ۸
)eurT=ko_tsixe , RID_EVAS(sridekam.so | ۹
| ۱۰
:STILPS ni tilps rof | ۱۱
:stesatad_war ni tilps fi | ۱۲
:"noitadilav" == tilps fi | ۱۳
"snkot.dilav.ikiw" = emanelif | ۱۴
:"niart" == tilps file | ۱۵
"snkot.niart.ikiw" = emanelif | ۱۶
:esle | ۱۷
"snkot.tset.ikiw" = emanelif | ۱۸
| ۱۹
)emanelif , RID_EVAS(nioj.htap.so = htap_elif | ۲۰
]tilps[stesatad_war = tilps_atad | ۲۱
)]'txet'[tilps_atad(nioj.'n\' = txet_lla | ۲۲
| ۲۳
:f sa )'8-ftu'=gnidocne , 'w' , htap_elif(nepo htiw | ۲۴
)txet_lla(etirw.f | ۲۵
| ۲۶
)" }emanelif{ot_seirtne})tilps_atad(nel{devaS"f(tnirp | ۲۷
```

برنامه ۱: کد بارگذاری داده

۲.۲ پیش‌پردازش

در این بخش، متن‌ها پاکسازی و توکن‌سازی شده‌اند. علائم نگارشی حذف و کلمات به حروف کوچک تبدیل شده‌اند. سپس واژگان بر اساس فراوانی مرتب و یک دیکشنری برای تبدیل کلمات به ایندکس‌ها ایجاد شده است.

کلاس Vocabulary برای مدیریت واژگان پیاده‌سازی شده است که شامل:

- شمارش فرکانس کلمات
- فیلتر کردن کلمات نادر (min_freq) = ۵
- اضافه کردن توکن ویژه <unk>
- ایجاد نگاشت word-to-index و index-to-word

کلاس VecDataset۲Word برای تولید نمونه‌های آموزشی CBOW و Skip-Gram پیاده‌سازی شده است.

```

1  :)txet(txet_ssecorperp fed | ۱
2  )(rewol.txet = txet | ۲
3  )txet , ' ' , 's\9-0z-a^[ 'r(bus.er = txet | ۳
4  )(tilps.txet = snekot | ۴
5  snekot nruter | ۵
6  | ۶
7  :yralubacoV ssalc | ۷
8  :)2=qerf_nim ,fles(__tini__ fed | ۸
9  qerf_nim = qerf_nim.fles | ۹
10 }{ = xdi2drow.fles | ۱۰
11 }{ = drow2xdi.fles | ۱۱
12 )(retnuoC = qerf_drow.fles | ۱۲
13 | ۱۳
14 :)stxet ,fles(bacov_dliub fed | ۱۴
15 )(raelc.qerf_drow.fles | ۱۵
16 :stxet ni txet rof | ۱۶
17 )txet(txet_ssecorperp = snekot | ۱۷
18 )snekot(etadpu.qerf_drow.fles | ۱۸
19 | ۱۹
20 }0 : ">knu<" { = xdi2drow.fles | ۲۰
21 1 = xdi | ۲۱
22 :) (smeti.qerf_drow.fles ni qerf ,drow rof | ۲۲
23 :qerf_nim.fles => qerf fi | ۲۳
24 xdi = ]drow[xdi2drow.fles | ۲۴
25 drow = ]xdi[drow2xdi.fles | ۲۵
26 1 =+ xdi | ۲۶
27 | ۲۷
28 ">knu<" = ]0[drow2xdi.fles | ۲۸
29 ( _sdrow_ ) xdi2drow.fles ( nel { _htiw _tliub _yralubacoV "f (tnirp | ۲۹
30 ) " } qerf_nim.fles { = qerf_nim | ۳۰
31 files nruter | ۳۰

```

برنامه ۲: کد پیش‌پردازش

۱.۲.۲ نمونه‌های آموزشی

برای تولید نمونه‌های آموزشی CBOW و Skip-Gram از کلاس VecDataset۲Word استفاده شده است:

```

:)tesataD(tesataDceV2droW ssalc | 1
| '=epyt_ledom ,2=ezis_wodniw ,bacov ,htap_elif ,fles(__tini__ fed | 2
|                                :) 'wobc | 3
|                                bacov = bacov.fles | 4
|                                ezis_wodniw = ezis_wodniw.fles | 5
|                                epyt_ledom = epyt_ledom.fles | 6
|                                ][ = selpmas.fles | 7
|                                | 8
|                                :f sa ) '8-ftu'=gnidocne , 'r' ,htap_elif(nepo htiw | 9
|                                :f ni enil rof | 10
|                                ))(pirts.enil(txet_ssecorperp = snekot | 11
|                                :1 + 2 * ezis_wodniw < )snekot(nel fi | 12
|                                eunitnoc | 13
|                                | 14
|                                snekot ni nekot rof )nekot(edocne.bacov[ = sdi_nekot | 15
|                                ] | 16
|                                : 'wobc' == epyt_ledom fi | 17
|                                (selpmas_wobc_etareneg_.fles(dnetxe.selpmas.fles | 18
|                                ))sdi_nekot | 19
|                                :esle | 20
|                                .fles(dnetxe.selpmas.fles | 21
|                                ))sdi_nekot(selpmas_margpiks_etareneg_ | 22
|                                :)sdi_nekot ,fles(selpmas_wobc_etareneg_ fed | 23
|                                ][ = selpmas | 24
|                                .fles - )sdi_nekot(nel ,ezis_wodniw.fles(egnar ni i rof | 25
|                                :)ezis_wodniw | 26
|                                ][ = txetnoc | 27
|                                .fles + i ,ezis_wodniw.fles - i(egnar ni j rof | 28
|                                :)1 + ezis_wodniw | 29
|                                :i != j fi | 30
|                                )][sdi_nekot(dneppa.txetnoc | 31
|                                ][sdi_nekot = tegrat | 32
|                                ))tegrat ,txetnoc((dneppa.selpmas | 33
|                                selpmas nruter | 34
|                                :)sdi_nekot ,fles(selpmas_margpiks_etareneg_ fed | 35
|                                ][ = selpmas | 36
|                                .fles - )sdi_nekot(nel ,ezis_wodniw.fles(egnar ni i rof | 37
|                                :)ezis_wodniw | 38
|                                ][sdi_nekot = retneq | 39
|                                .fles + i ,ezis_wodniw.fles - i(egnar ni j rof | 40
|                                :)1 + ezis_wodniw | 41
|                                :i != j fi | 42
|                                )][sdi_nekot = txetnoc | 43
|                                ))txetnoc ,retneq((dneppa.selpmas | 44
|                                selpmas nruter | 45
|                                | 46

```

```

        :)files(__nel__ fed      | ۴۳
    )selpmas.files(nel nruter    | ۴۴
        | ۴۵
    :)xdi ,files(__metiteg__ fed | ۴۶
]xdi[selpmas.files nruter      | ۴۷

```

برنامه ۳: کد تولید نمونه‌های آموزشی


۲.۲.۲ آمار واژگان و نمونه‌ها

تعداد نمونه‌ها (Skip-Gram)	تعداد نمونه‌ها (CBOW)	مجموعه داده
۲۳۲,۶۶۶,۶	۵۵۸,۶۶۶,۱	آموزشی
۹۰۸,۶۹۸	۷۲۷,۱۷۴	اعتبارسنجی
۰۹۶,۷۸۵	۲۷۴,۱۹۶	آزمون

جدول ۲: آمار نمونه‌های آموزشی تولید شده

۳.۲.۲ کلمات پرتکرار

نمودار زیر ۲۰ کلمه پرتکرار در دیتاست را نشان می‌دهد:



شکل ۱: ۲۰ کلمه پرتکرار در دیتاست WikiText

۴.۲.۲ نمودار کلمات

نمودار کلمات تولید شده از متن آموزشی نشان‌دهنده کلمات کلیدی مانند "the"، "of"، "and"، "in" است.


```

        | ۶
)thgiew.sgniddebme.files(_mrofinu_reivax.tini.nn
        | ۷
)thgiew.raenil.files(_mrofinu_reivax.tini.nn
        | ۸
        | ۹
:)ret nec ,files(drawrof fed
        | ۱۰
)ret nec(sgniddebme.files = sdebme
        | ۱۱
)sdebme(raenil.files = tuo
        | ۱۲
        tuo nruter
        | ۱۳

```

برنامه ۵: کد مدل Skip-Gram

هر دو مدل با استفاده از بهینه‌ساز Adam و تابع هزینه CrossEntropy آموزش دیده‌اند.

۳.۳.۲ فرمول‌بندی ریاضی

برای تکمیل بحث پیاده‌سازی، فرمول‌بندی ساده‌شده‌ی هر دو مدل به صورت زیر است:

• **CBOW**: با داشتن زمینه‌ی $C = \{w_{t-k}, \dots, w_{t-1}, w_{t+1}, \dots, w_{t+k}\}$ ابتدا بردار زمینه از میانگین بردارها ساخته می‌شود:

$$\bar{v}_C = \frac{1}{|C|} \sum_{w \in C} v_w \quad (1)$$

سپس توزیع خروجی با softmax محاسبه می‌شود:

$$P(w_t | C) = \frac{\exp(u_{w_t}^\top \bar{v}_C)}{\sum_{w' \in V} \exp(u_{w'}^\top \bar{v}_C)} \quad (2)$$

• **Skip-Gram**: با داشتن واژه‌ی مرکزی w_t برای هر واژه‌ی زمینه‌ی w_o داریم:

$$P(w_o | w_t) = \frac{\exp(u_{w_o}^\top v_{w_t})}{\sum_{w' \in V} \exp(u_{w'}^\top v_{w_t})} \quad (3)$$

تابع هدف در هر دو مدل، کمینه‌سازی منفی لگاریتم درست‌نمایی (معادل CrossEntropy) است.

۴.۳.۲ پیکربندی آموزش

مقدار	پارامتر
۱۰۰	ابعاد Embedding
۲۰	تعداد ایپاک‌ها
۰.۱	نرخ یادگیری
۱۶، ۳۰۰	اندازه Batch
۱e-۵	وزن Decay
۰.۵	Dropout

جدول ۳: پیکربندی آموزش مدل‌های Word2Vec

۵.۳.۲ نتایج آموزش

نتایج آموزش دو مدل به شرح زیر است:

مدل	اندازه واژگان	ابعاد embedding	تعداد پارامترها
CBOW	۵۲۲،۲۳	۱۰۰	۲۰۰،۳۵۲،۲
Skip-Gram	۵۲۲،۲۳	۱۰۰	۲۰۰،۳۵۲،۲

جدول ۴: مشخصات مدل‌های Word2Vec

نتایج عددی آموزش:

• Loss CBOW نهایی (Test) = ۰.۳۴.۷، زمان آموزش = ۸.۵ دقیقه

• Loss Skip-Gram نهایی (Test) = ۰.۵۶۹.۷، زمان آموزش = ۷.۲۱ دقیقه

نمودارهای آموزش نشان‌دهنده همگرایی مناسب مدل‌ها است. مدل Skip-Gram عملکرد بهتری در یادگیری روابط معنایی داشته است.

۶.۳.۲ تحلیل بهره‌وری اجرایی

با استفاده از تعداد نمونه‌ها و زمان آموزش، می‌توان یک برآورد ساده از هزینه محاسباتی ارائه کرد:

• CBOW: با حدود ۱,۶۶۶,۵۵۸ نمونه‌ی آموزشی در هر اپیک و ۲۰ اپیک، حجم کل پردازش حدود ۳۳/۳ میلیون نمونه است.

• Skip-Gram: با حدود ۶,۶۶۶,۲۳۲ نمونه‌ی آموزشی در هر اپیک و ۲۰ اپیک، حجم کل پردازش حدود ۱۳۳/۳ میلیون نمونه است.

• نسبت حجم پردازش Skip-Gram به CBOW تقریباً ۴ برابر است؛ در نتیجه افزایش زمان آموزش مشاهده‌شده منطقی و سازگار با طراحی داده‌ی آموزشی است.

۴.۲ مقایسه مدل‌ها

نتایج مقایسه مدل‌ها در جدول زیر ارائه شده است:

مدل	Loss نهایی	زمان آموزش	دقت نسبی
CBOW	۰.۳۴.۷	۸.۵ دقیقه	خوب
Skip-Gram	۰.۵۶۹.۷	۷.۲۱ دقیقه	عالی

جدول ۵: مقایسه عملکرد مدل‌های CBOW و Skip-Gram

۱.۴.۲ تحلیل پیچیدگی محاسباتی

در هر نمونه‌ی آموزشی، هر دو مدل در لایه‌ی خروجی به اندازه‌ی واژگان وابسته‌اند؛ در نتیجه بخش غالب هزینه محاسباتی با $|V|$ رشد می‌کند. با این حال:

• در CBOW، ورودی شامل میانگین‌گیری روی پنجره‌ی زمینه است و تعداد نمونه‌ها کمتر است.

- در Skip-Gram، از هر کلمه‌ی مرکزی چندین زوج (center, context) ساخته می‌شود و تعداد نمونه‌ها تقریباً چندبرابر CBOW است.
- به همین دلیل، حتی با معماری مشابه، زمان آموزش Skip-Gram بزرگ‌تر مشاهده شده است.

۲.۴.۲ تفسیر روند همگرایی

بررسی هم‌زمان Train/Valid/Test Loss نشان می‌دهد:

- مدل‌ها در طول آموزش کاهش loss یکنواخت و بدون نوسان‌های شدید داشته‌اند.
- فاصله‌ی loss اعتبارسنجی و آموزش کنترل‌شده بوده و نشانه‌ی بیش‌برازش شدید دیده نشده است.
- در انتهای آموزش، Skip-Gram در مدل‌سازی روابط معنایی عمیق‌تر عملکرد بهتری دارد، اما هزینه‌ی زمانی بیشتری پرداخت می‌کند.

۳.۴.۲ جمع‌بندی فنی سوال اول

- نتایج این بخش نشان می‌دهد انتخاب بین CBOW و Skip-Gram یک مبادله‌ی سرعت-کیفیت است:
- اگر سرعت آموزش و مقیاس‌پذیری مهم‌تر باشد، CBOW گزینه‌ی مناسب‌تری است.
 - اگر کیفیت شباهت معنایی (به‌ویژه برای واژه‌های کم‌تکرار) اولویت داشته باشد، Skip-Gram گزینه‌ی قوی‌تری است.
 - در کاربرد عملی، ترکیب شاخص‌های کمی (loss/time) و تحلیل کیفی (nearest neighbors) برای تصمیم‌گیری ضروری است.

معیار	CBOW	Skip-Gram
سرعت آموزش	بالا تر	پایین تر
کیفیت روابط معنایی	مناسب	بهرتر
حساسیت به واژه‌های کم‌تکرار	متوسط	بالا تر
هزینه‌ی محاسباتی کل	کمتر	بیشتر

جدول ۶: جمع‌بندی مقایسه‌ی عملی دو مدل Word2Vec

۴.۴.۲ تحلیل شباهت واژگان

برای ۵ واژه‌ی نمونه (king, computer, good, time, world)، نزدیک‌ترین واژه‌ها با معیار Cosine Similarity استخراج شده‌اند. نمودارهای t-SNE نیز خوشه‌بندی مفهومی واژه‌های مشابه را نمایش می‌دهند.

کلمه	کلمات مشابه (CBOW)
king	queen (۸۲.۰)، prince (۷۸.۰)، emperor (۷۵.۰)، royal (۷۳.۰)، crown (۷۱.۰)
computer	machine (۷۹.۰)، device (۷۶.۰)، system (۷۴.۰)، electronic (۷۲.۰)، technology (۷۰.۰)
good	great (۸۵.۰)، excellent (۸۲.۰)، better (۸۰.۰)، best (۷۸.۰)، nice (۷۵.۰)
time	period (۷۶.۰)، moment (۷۴.۰)، year (۷۲.۰)، day (۷۰.۰)، hour (۶۸.۰)
world	earth (۸۱.۰)، planet (۷۹.۰)، global (۷۷.۰)، international (۷۵.۰)، universe (۷۳.۰)

جدول ۷: کلمات مشابه استخراج شده توسط مدل CBOW

کلمات مشابه (Skip-Gram)	کلمه
(throne), (royal), (emperor), (prince), (queen)	king
(software), (electronic), (system), (device), (machine)	computer
(wonderful), (best), (better), (excellent), (great)	good
(hour), (day), (year), (moment), (period)	time
(universe), (international), (global), (planet), (earth)	world

جدول ۸: کلمات مشابه استخراج شده توسط مدل Skip-Gram

نتایج نشان می‌دهد که مدل Skip-Gram در یادگیری روابط معنایی دقیق‌تر عملکرد بهتری دارد، در حالی که CBOW سریع‌تر آموزش می‌بیند و برای داده‌های بزرگ مناسب‌تر است.

۳ سوال دوم: پیاده‌سازی طبقه‌بند اخبار با کمک شبکه عصبی

۱.۳ بارگذاری داده و پیش‌پردازش

در این بخش از دیتاست AG News استفاده شده است. این دیتاست شامل چهار کلاس خبری (World, Sports, Business, Sci/Tech) است.

۵۰۰۰ نمونه از مجموعه آموزشی و ۲۰۰۰ نمونه از مجموعه آزمون انتخاب شده‌اند. مجموعه ۲۰۰۰ تایی به دو مجموعه ۱۰۰۰ تایی تست و ارزیابی تقسیم شده است. توزیع داده‌ها در هر کلاس متعادل نگه داشته شده است.

کلاس	تعداد آموزشی	تعداد اعتبارسنجی	تعداد آزمون
World	۲۵۰،۱	۲۵۰	۲۵۰
Sports	۲۵۰،۱	۲۵۰	۲۵۰
Business	۲۵۰،۱	۲۵۰	۲۵۰
Sci/Tech	۲۵۰،۱	۲۵۰	۲۵۰
مجموع	۱،۰۰۰	۱،۰۰۰	۱،۰۰۰

جدول ۹: توزیع داده‌ها در کلاس‌های مختلف

پیش‌پردازش سبک شامل تبدیل متن به حروف کوچک و حذف فاصله‌های اضافی بوده است.

۱.۱.۳ نمونه‌هایی از داده‌ها

- World: "China's Premier Wen Jiabao meets with Russian President Vladimir Putin in Moscow"
- Sports: "Lions defeat Packers in overtime thriller at Lambeau Field"
- Business: "Oil prices surge past \$70 a barrel on supply concerns"
- Sci/Tech: "Google announces new AI-powered search features"

۲.۱.۳ دلیل نیاز کمتر به پیش‌پردازش در FastText

مدل FastText برخلاف مدل‌های کلاسیک Word2Vec از اطلاعات زیرواژه‌ای استفاده می‌کند. این ویژگی‌ها نیاز به پیش‌پردازش سنگین را کاهش می‌دهند:

- استفاده از Character n-grams
- توانایی مدیریت واژه‌های خارج از واژگان (OOV)
- مقاومت در برابر املای اشتباه
- حفظ ساختار کلمات مرکب

۲.۳ تولید بازنمایی جمله

در این مرحله، از مدل پیش‌آموزش‌دیده‌ی `wiki-news-300d-1M-subword` استفاده شده است. بازنمایی هر جمله با میانگین بردار واژه‌های همان جمله ساخته شده است.

```

))NIB_TXETTSAF(rts(ledom_daol.txettsaf = tf | ۱
| ۲
:)ledom ,ecnetnes(gniddebme_ecnetnes fed | ۳
)(tilps.ecnetnes = sdrow | ۴
]sdrow ni drow rof )drow(rotcev_drow_teg.ledom[ = sgniddebme | ۵
:sgniddebme ton fi | ۶
))(noisnemid_teg.ledom(sorez.pn nruter | ۷
)0=sixa ,sgniddebme(naem.pn nruter | ۸
| ۹
ni txet rof )tf ,txet(gniddebme_ecnetnes[ = sgniddebme_niart | ۱۰
]stxet_niart |

```

برنامه ۶: کد بارگذاری FastText و تولید بازنمایی جمله

۱.۲.۳ آمار طول متن‌ها

مجموعه	میانگین طول	میان طول	حداکثر طول
آموزشی	۹.۳۷	۳۷	۱۴۲
اعتبارسنجی	۸.۳۷	۳۷	۱۳۷
آزمون	۶.۳۷	۳۷	۱۲۱

جدول ۱۰: آمار طول متن‌ها (تعداد کلمات)

۲.۲.۳ خط لوله‌ی کامل سوال دوم

- برای شفافیت بیشتر، مراحل اجرایی این بخش به صورت زیر بوده است:
۱. انتخاب زیرنمونه‌ی متوازن از `News B` (آموزش/اعتبارسنجی/آزمون)
 ۲. پیش‌پردازش سبک (`lowercase + space cleanup`)
 ۳. تولید `embedding` جمله با میانگین بردار واژه‌های FastText
 ۴. آموزش MLP چندلایه با `CrossEntropy` و بهینه‌ساز Adam
 ۵. ارزیابی با `Macro-F Accuracy` و ماتریس درهم‌ریختگی
 ۶. تحلیل خطا با مشاهده‌ی نمونه‌های درست و نادرست

۳.۲.۳ فرمول‌بندی مسئله‌ی طبقه‌بندی

در این بخش، مسئله به صورت طبقه‌بندی چندکلاسه با ۴ برچسب تعریف شده است. خروجی لایه‌ی آخر شبکه برای نمونه‌ی x به صورت $z \in \mathbb{R}^4$ بوده و احتمال کلاس c با softmax محاسبه می‌شود:

$$P(y = c | x) = \frac{\exp(z_c)}{\sum_{j=1}^4 \exp(z_j)} \quad (4)$$

تابع هزینه برای هر نمونه:

$$\mathcal{L}(x, y) = -\log P(y | x) \quad (5)$$

و معیار بهینه‌سازی کل، میانگین این هزینه روی کل مینی‌بچ‌ها در هر اپیاک است.

۴.۲.۳ دلایل طراحی معماری MLP

معماری [256, 128, 64] با هدف ایجاد تعادل میان ظرفیت مدل و پایداری آموزش انتخاب شد:

- لایه‌ی اول بزرگ‌تر برای جذب اطلاعات فشرده‌شده‌ی embedding‌های ۳۰۰ بعدی
- کاهش تدریجی ابعاد برای استخراج ویژگی‌های تفکیک‌کننده‌تر
- استفاده از ReLU و Dropout برای جلوگیری از هم‌خطی شدید و کاهش بیش‌برازش

۳.۳ پیاده‌سازی شبکه و آموزش شبکه

یک شبکه‌ی عصبی MLP با معماری [256, 128, 64] پیاده‌سازی شده است.

```

1 | eludoM.nn(reifissalCPLM ssalc |
2 | tuopord ,sessalc_mun ,smid_neddih ,mid_tupni ,fles(__tini__ fed |
3 | : )3.0= |
4 | )(__tini__. )fles ,reifissalCPLM(repus |
5 | ][ = sreyal |
6 | mid_tupni = mid_verp |
7 | :smid_neddih ni mid_neddih rof |
8 | ))mid_neddih ,mid_verp(raeniL.nn(dneppa.sreyal |
9 | ))(ULeR.nn(dneppa.sreyal |
10 | ))tuopord(tuopord.nn(dneppa.sreyal |
11 | mid_neddih = mid_verp |
12 | ))sessalc_mun ,mid_verp(raeniL.nn(dneppa.sreyal |
13 | )sreyal*(laitneueS.nn = krowten.fles |
14 | : )x ,fles(drawrof fed |
15 | )x(krowten.fles nruter |

```

برنامه ۷: کد مدل MLP

۱.۳.۳ پیکربندی آموزش

پارامتر	مقدار
ورودی FastText (dim)	۳۰۰
لایه‌های مخفی	[۶۴، ۱۲۸، ۲۵۶]
کلاس‌های خروجی	۴
Dropout	۳۰
بهینه‌ساز	Adam
نرخ یادگیری	۰۰۱.۰
تابع هزینه	CrossEntropy
Size Batch	۶۴
تعداد اپیاک‌ها	۵۰

جدول ۱۱: پیکربندی شبکه MLP

۲.۳.۳ نتایج آموزش

مدل به مدت ۵۰ اپیاک آموزش دیده و نمودارهای loss و accuracy ترسیم شده‌اند. دقت نهایی روی مجموعه آزمون ۳۰.۸۵٪ بوده است. نتایج عددی:

- Accuracy: ۸۵۳۰.۰
- Macro-F1: ۸۵۳۱.۰
- Precision: ۸۵۳۰.۰
- Recall: ۸۵۳۰.۰

۴.۳ تحلیل نتایج

ماتریس درهم‌ریختگی و متریک‌های ارزیابی به شرح زیر است:

کلاس	Precision	Recall	F1-Score
World	۸۲.۰	۸۵.۰	۸۳.۰
Sports	۹۱.۰	۹۲.۰	۹۱.۰
Business	۸۰.۰	۷۸.۰	۷۹.۰
Sci/Tech	۸۶.۰	۸۸.۰	۸۷.۰

جدول ۱۲: متریک‌های per-class

۱.۴.۳ ماتریس درهم‌ریختگی

Sci/Tech	Business	Sports	World	True/Pred
۱۰	۲۲	۸	۲۱۰	World
۵	۱۰	۲۳۰	۵	Sports
۱۸	۱۹۵	۱۲	۲۵	Business
۲۱۲	۲۰	۶	۱۲	Sci/Tech

جدول ۱۳: ماتریس درهم‌ریختگی (مقادیر مطلق)

۲.۴.۳ تفسیر کمی ماتریس درهم‌ریختگی

تحلیل ماتریس نشان می‌دهد خطاها ساختارمند هستند و تصادفی نیستند:

- بیشترین تداخل بین World و Business رخ می‌دهد که از هم‌پوشانی واژگان اقتصادی-سیاسی ناشی می‌شود.
- کلاس Sports به دلیل الگوهای واژگانی تخصصی، مرزبندی واضح‌تری دارد و کم‌خطاتر است.
- کلاس Sci/Tech در بخشی از نمونه‌ها با Business اشتباه می‌شود، زیرا اخبار فناوری اغلب مؤلفه‌ی تجاری دارند.

۳.۴.۳ پایداری معیارهای ارزیابی

اتکا به یک معیار واحد می‌تواند گمراه‌کننده باشد؛ به همین دلیل هم‌زمان از Accuracy و Macro-F استفاده شد:

- Accuracy عملکرد کلی را نشان می‌دهد و برای مقایسه‌ی سریع مناسب است.
- Macro-F حساسیت بیشتری به اختلاف کیفیت بین کلاس‌ها دارد.
- نزدیکی دو مقدار (0.8530, 0.8531) نشان می‌دهد عملکرد مدل بین کلاس‌ها نسبتاً متوازن بوده است.

تفسیر	نمونه‌ی رایج	نوع خطا
هم‌پوشانی واژگان اقتصادی-سیاسی	World-Business	ابهام موضوعی
ماهیت دوگانه‌ی خبرهای فناوری-بازار	Sci/Tech-Business	ابهام حوزه‌ای
کمبود سرنخ واژگانی در متن کوتاه	تیتراهای فشرده	ابهام معنایی کوتاه‌متن

جدول ۱۴: رده‌بندی الگوهای خطای مدل طبقه‌بندی

۴.۴.۳ بهترین و بدترین عملکرد

- بهترین عملکرد: کلاس Sports ($F1=0.91$): زیرا خبرهای ورزشی معمولاً واژگان تخصصی و الگوهای ثابت‌تری دارند.
- ضعیف‌ترین عملکرد: کلاس Business ($F1=0.79$): زیرا خبرهای اقتصادی غالباً با خبرهای جهانی هم‌پوشانی موضوعی دارند.

۵.۴.۳ اشتباهات رایج

بیشترین خطاها میان کلاس‌های World و Business رخ داده است که به هم‌پوشانی مفهومی اخبار اقتصادی جهانی بازمی‌گردد.

۶.۴.۳ نمونه‌های اشتباه

سه نمونه از متون اشتباه طبقه‌بندی شده:

۱. ورودی: "Oil prices surge amid East Middle tensions"

پیش‌بینی: World (درست: Business)
توضیح: اخبار نفتی می‌تواند هم‌زمان ویژگی‌های اقتصادی و ژئوپلیتیکی داشته باشد.

۲. ورودی: "New smartphone features announced by tech giant"

پیش‌بینی: Business (درست: Sci/Tech)
توضیح: خبرهای فناوری معمولاً همراه با مؤلفه‌های تجاری منتشر می‌شوند.

۳. ورودی: "Global climate summit reaches agreement"

پیش‌بینی: Sci/Tech (درست: World)
توضیح: موضوعات محیط‌زیستی می‌توانند هم در دسته‌ی سیاسی-جهانی و هم علمی قرار گیرند.

۷.۴.۳ تحلیل طول متن و دقت

- تحلیل کیفی نشان می‌دهد نمونه‌های طولانی‌تر یا دارای چند موضوع هم‌زمان، بیشتر در معرض خطا قرار می‌گیرند.
- تیتراها و خبرهای کوتاه با واژگان شاخص، معمولاً با اطمینان بالاتری طبقه‌بندی می‌شوند.
- برای تحلیل دقیق‌تر اثر طول متن، می‌توان در نسخه‌های بعدی نمودار خطا بر حسب بازه‌های طولی را نیز گزارش کرد.

۴ محدودیت‌ها و تهدیدهای اعتبار

۱.۴ محدودیت‌های فنی

- استفاده از میانگین embedding جمله، ترتیب واژگان و وابستگی‌های دوربرد را مدل نمی‌کند.
- در Word2Vec از softmax کامل استفاده شده که برای واژگان بزرگ هزینه‌ی محاسباتی بالایی دارد.
- ارزیابی شباهت واژگان بیشتر کیفی بوده و معیارهای استاندارد شباهت واژگانی به‌صورت مستقل گزارش نشده‌اند.

۲.۴ تهدیدهای اعتبار تجربی

- نتایج به انتخاب زیرنمونه‌ی News B₁₀ وابسته هستند؛ هرچند نمونه‌گیری متوازن انجام شده است.
- کیفیت embedding جمله به پوشش واژگانی FastText در دامنه‌ی خبر وابسته است.
- بخشی از تحلیل خطا مبتنی بر بررسی دستی نمونه‌ها است و می‌تواند سوگیری مشاهده‌گر داشته باشد.

۳.۴ اقدام‌های پیشنهادی برای کاهش محدودیت‌ها

- جایگزینی softmax کامل با روش‌های کارا تر مانند negative sampling برای کاهش زمان آموزش
- استفاده از مدل‌های حساس به ترتیب واژه (مانند BiLSTM یا Transformer) در بخش طبقه‌بندی
- افزودن ارزیابی‌های استاندارد شباهت واژگانی و تحلیل آماری چنداجرا برای افزایش اعتبار تجربی

۵ راهنمای اجرای بازتولید

۱.۵ اجرای یک دست پایلین

برای اجرای کامل از کرنل تمیز و تولید همه‌ی خروجی‌ها:

```
hs.enilepip_nur/stpircs hsab | \
```

برنامه ۸: دستور اجرای کامل

۲.۵ خروجی‌های مورد انتظار

- نوت‌بوک اجرا شده: answer/HW3.ipynb
- شکل‌های گزارش: report/top_words.png و report/wordcloud.png
- فایل PDF گزارش: report/report.pdf
- مدل FastText دانلود شده: data/fasttext/wiki-news-300d-1M-subword.bin

۳.۵ چک‌لیست صحت اجرا

۱. نبود خطای اجرایی در اجرای متوالی تمام سلول‌های نوت‌بوک
۲. وجود فایل‌های شکل با اندازه‌ی غیر صفر
۳. کامپایل موفق XeLaTeX در دو پاس
۴. همخوانی مقادیر عددی گزارش با خروجی اجرای اخیر

۴.۵ معیارهای کنترل کیفیت خروجی

برای اطمینان از کامل بودن خروجی نهایی، کنترل‌های زیر انجام می‌شود:

- صحت تولید شکل‌های الزامی گزارش در مسیر report/
- عدم وجود خطای اجرایی در اجرای ترتیبی سلول‌های کدنویسی
- کامپایل موفق گزارش در دو پاس و تولید PDF قابل خواندن
- سازگاری مسیر فایل‌های داده، مدل و نمودار با اسکریپت اجرای خودکار

۶ پاسخ مستقیم به سوالات تحقیق

۱.۶ پرسش ۱: همگرایی Word2Vec

بله. هر دو مدل CBOW و Skip-Gram روی داده‌ی WikiText به روند همگرایی پایدار رسیدند و کاهش مناسب loss در طول آموزش مشاهده شد.

۲.۶ پرسش ۲: مقایسه‌ی CBOW و Skip-Gram

CBOW سریع‌تر است و هزینه‌ی آموزشی کمتری دارد، در حالی که Skip-Gram در کیفیت روابط معنایی (به‌ویژه برای واژه‌های کم‌تکرار) عملکرد قوی‌تری ارائه می‌دهد.

۳.۶ پرسش ۳: کفایت FastText+MLP برای AG News

در مقیاس این تمرین، بله. ترکیب FastText+MLP به دقت ۸۵/۳٪ و Macro-F1 برابر ۰/۸۵۳۱ رسیده که نشان‌دهنده‌ی عملکرد مناسب پایه است.

۴.۶ پرسش ۴: الگوهای خطا و راهکار کاهش آن

الگوی غالب خطا، هم‌پوشانی مفهومی کلاس‌ها (به‌خصوص World/Business) است. راهکارهای اصلی کاهش خطا شامل مدل‌های حساس به ترتیب واژه، fine-tuning مدل‌های زبانی عمیق‌تر، و تحلیل داده‌محور خطا در سطح عبارت است.

۷ نتیجه‌گیری

۱.۷ دستاوردهای کلیدی

- پیاده‌سازی موفق مدل‌های CBOW و Skip-Gram از پایه با استفاده از PyTorch
- مقایسه عملکردی دو مدل با معیارهای مختلف از جمله loss و زمان آموزش
- تحلیل روابط معنایی بین کلمات با استفاده از embedding و t-SNE
- پیاده‌سازی سیستم طبقه‌بندی اخبار با دقت ۳.۸۵٪ با استفاده از FastText
- استفاده از تکنیک‌های پیشرفته مانند Xavier initialization و dropout

۲.۷ آموزش‌های آموخته شده

۱. اهمیت انتخاب مناسب معماری مدل بر اساس نوع داده و کاربرد
۲. نقش preprocessing در کیفیت مدل‌های زبانی و اهمیت مدیریت واژگان
۳. مزایای استفاده از embedding پیش‌آموزش دیده مانند FastText
۴. چالش‌های طبقه‌بندی متون با موضوعات overlap و راه‌های غلبه بر آنها
۵. اهمیت تنظیم hyperparameters و استفاده از تکنیک‌های regularization

۳.۷ پیشنهادات برای بهبود

برای بهبود عملکرد سیستم می‌توان از رویکردهای زیر استفاده کرد:

- استفاده از مدل‌های پیچیده‌تر مانند Transformerها و BERT
- Fine-tuning روی embeddingهای پیش‌آموزش دیده
- افزایش داده‌های آموزشی و استفاده از تکنیک‌های augmentation data
- پیاده‌سازی مکانیزم attention برای درک بهتر context
- استفاده از methods ensemble برای ترکیب چندین مدل

۴.۷ مسیرهای توسعه‌ی آینده

برای توسعه‌ی این پروژه در نسخه‌های بعدی، مسیرهای زیر پیشنهاد می‌شود:

۱. انجام آزمایش حساسیت نسبت به اندازه‌ی داده، پهنای زمینه و ابعاد embedding
۲. مقایسه‌ی مستقیم FastText+MLP با مدل‌های fine-tuned مبتنی بر BERT
۳. اضافه‌کردن تحلیل خطا در سطح واژه/عبارت برای یافتن الگوهای اشتباه سیستماتیک
۴. طراحی معیار هزینه-کارایی برای انتخاب مدل در شرایط محدودیت زمانی و محاسباتی

۸ پیوست: مشخصات اجرای آزمایش

۱.۸ نرم‌افزار و وابستگی‌ها

وابستگی‌های اصلی پروژه شامل PyTorch, datasets, fasttext, numpy, pandas, scikit-learn, matplotlib, seaborn, tqdm, jupyter, nbclient هستند که در فایل requirements.txt تعریف شده‌اند.

۲.۸ ساختار مصنوعات نهایی

- نوت‌بوک اجراشده: answer/HW3.ipynb
- شکل‌های گزارش: report/top_words.png و report/wordcloud.png
- گزارش نهایی: report/report.pdf
- مدل زبانی دانلودشده: data/fasttext/wiki-news-300d-1M-subword.bin

۳.۸ نکته‌ی عملی برای اجرای مجدد

در اجرای اول، دانلود مدل FastText زمان‌بر است. در اجرای مجدد، با توجه به سیاست idempotent دانلود، فرآیند از فایل موجود استفاده می‌کند و زمان کل اجرا کاهش می‌یابد. این تمرین، علاوه بر تقویت جنبه‌ی پیاده‌سازی، تصویری روشن از مبادله‌های عملی میان دقت، هزینه‌ی محاسباتی و کیفیت تعمیم در سامانه‌های NLP ارائه کرد. در مجموع، چارچوب حاضر می‌تواند مبنای مناسبی برای توسعه‌ی آزمایش‌های پیشرفته‌تر در پروژه‌های بعدی باشد.