

گزارش تمرین سوم: Mhs & Vec2Word

محمد طاها مجلسی
شماره دانشجویی: ۸۱۰۱۰۱۵۰۴

۱۵/۱۰/۱۴۰۲

فهرست مطالب

۳	۱	مقدمه
۳	۲	سوال اول: پیاده‌سازی CBOW و Skip-Gram
۳	۱.۲	بارگذاری داده
۴	۲.۲	پیش‌پردازش
۵	۱.۲.۲	نمونه‌های آموزشی
۶	۲.۲.۲	آمار واژگان و نمونه‌ها
۶	۳.۲.۲	کلمات پرتکرار
۶	۴.۲.۲	نمودار کلمات
۷	۳.۲	پیاده‌سازی شبکه و آموزش شبکه
۷	۱.۳.۲	مدل CBOW
۷	۲.۳.۲	مدل Skip-Gram
۸	۳.۳.۲	پیکربندی آموزش
۸	۴.۳.۲	نتایج آموزش
۹	۴.۲	مقایسه مدل‌ها
۹	۱.۴.۲	تحلیل شباهت واژگان
۹	۳	سوال دوم: پیاده‌سازی طبقه‌بند اخبار با کمک شبکه عصبی و مدل Fasttext
۹	۱.۳	بارگذاری داده و پیش‌پردازش
۱۰	۱.۱.۳	نمونه‌هایی از داده‌ها
۱۰	۲.۱.۳	دلیل نیاز کمتر به پیش‌پردازش در FastText
۱۰	۲.۳	Embedding نمونه‌ها
۱۱	۱.۲.۳	آمار طول متن‌ها
۱۱	۳.۳	پیاده‌سازی شبکه و آموزش شبکه
۱۱	۱.۳.۳	پیکربندی آموزش
۱۲	۲.۳.۳	نتایج آموزش
۱۲	۴.۳	تحلیل نتایج
۱۲	۱.۴.۳	ماتریس درهم‌ریختگی
۱۲	۲.۴.۳	بهترین و بدترین عملکرد
۱۲	۳.۴.۳	اشتباهات رایج

۱۳	۴.۴.۳	نمونه‌های اشتباه	۴
۱۳	۵.۴.۳	تحلیل طول متن و دقت	
۱۳		نتیجه‌گیری	۴
۱۳	۱.۴	دستاوردهای کلیدی	
۱۳	۲.۴	آموزش‌های آموخته شده	
۱۴	۳.۴	پیشنهادهای برای بهبود	

۱ مقدمه

در این گزارش، پیاده‌سازی و تحلیل دو مدل یادگیری ماشین در حوزه پردازش زبان طبیعی ارائه شده است. ابتدا مدل‌های Vec2Word شامل CBOW و Skip-Gram از پایه پیاده‌سازی شده‌اند و سپس یک سیستم طبقه‌بندی اخبار با استفاده از FastText و شبکه‌های عصبی پیاده‌سازی گردیده است.

۲ سوال اول: پیاده‌سازی CBOW و Skip-Gram

۱.۲ بارگذاری داده

برای این بخش از دیتاست WikiText-۲ استفاده شده است که شامل متن‌های ویکی‌پدیا است. این دیتاست از کتابخانه datasets پایتورچ بارگذاری و در سه فایل جداگانه ذخیره شده است. آمار دیتاست به شرح زیر است:

- مجموعه آموزشی: ۷۱۸،۳۶ خط، ۵۴۰،۰۸۸،۲ کلمه، ۲۷۸،۳۳ کلمه منحصر به فرد
- مجموعه اعتبارسنجی: ۷۶۰،۳ خط، ۶۴۶،۲۱۷ کلمه، ۶۲۷،۱۳ کلمه منحصر به فرد
- مجموعه آزمون: ۳۴۶،۴ خط، ۰۱۹،۲۴۶ کلمه، ۵۳۵،۱۴ کلمه منحصر به فرد

```
"txetikiw" = EMAN_TESATAD | ۱
"1v-war-2-txetikiw" = GIFNOC_TESATAD | ۲
"2-txetikiw/atad" = RID_EVAS | ۳
]"tset" , "noitadilav" , "niart"[ = STILPS | ۴
| ۵
)"...tesatad_}GIFNOC_TESATAD{_gnidaoL"f(tnirp | ۶
) GIFNOC_TESATAD , EMAN_TESATAD(tesatad_daol = stesatad_war | ۷
| ۸
)eurT=ko_tsixe , RID_EVAS(sridekam.so | ۹
| ۱۰
:STILPS ni tilps rof | ۱۱
:stesatad_war ni tilps fi | ۱۲
:"noitadilav" == tilps fi | ۱۳
"snkot.dilav.ikiw" = emanelif | ۱۴
:"niart" == tilps file | ۱۵
"snkot.niart.ikiw" = emanelif | ۱۶
:esle | ۱۷
"snkot.tset.ikiw" = emanelif | ۱۸
| ۱۹
)emanelif , RID_EVAS(nioj.htap.so = htap_elif | ۲۰
]tilps[stesatad_war = tilps_atad | ۲۱
)]'txet'[tilps_atad(nioj.'n\' = txet_lla | ۲۲
| ۲۳
:f sa )'8-ftu'=gnidocne , 'w' , htap_elif(nepo htiw | ۲۴
)txet_lla(etirw.f | ۲۵
| ۲۶
)" }emanelif{_ot_ seirtne_})tilps_atad(nel{_devaS"f(tnirp | ۲۷
```

برنامه ۱: کد بارگذاری داده

۲.۲ پیش‌پردازش

در این بخش، متن‌ها پاکسازی و توکن‌سازی شده‌اند. علائم نگارشی حذف و کلمات به حروف کوچک تبدیل شده‌اند.

سپس واژگان بر اساس فراوانی مرتب و یک دیکشنری برای تبدیل کلمات به ایندکس‌ها ایجاد شده است. کلاس Vocabulary برای مدیریت واژگان پیاده‌سازی شده است که شامل:

- شمارش فرکانس کلمات

- فیلتر کردن کلمات نادر $(\text{min_freq} = 5)$

- اضافه کردن توکن ویژه <unk>

- ایجاد دیکشنری دوطرفه word index و index word

کلاس VecDataset۲Word برای تولید نمونه‌های آموزشی CBOW و Skip-Gram پیاده‌سازی شده است.

```

1  :)txet(txet_ssecorperp fed | ۱
2  )(rewol.txet = txet | ۲
3  )txet , ' ' , 's\9-0z-a~['r(bus.er = txet | ۳
4  )(tilps.txet = snekot | ۴
5  snekot nruter | ۵
6  | ۶
7  :yralubacoV ssalc | ۷
8  :)2=qerf_nim ,fles(__tini__ fed | ۸
9  qerf_nim = qerf_nim.fles | ۹
10  }{ = xdi2drow.fles | ۱۰
11  }{ = drow2xdi.fles | ۱۱
12  )(retnuoC = qerf_drow.fles | ۱۲
13  | ۱۳
14  :)stxet ,fles(bacov_dliub fed | ۱۴
15  )(raelc.qerf_drow.fles | ۱۵
16  :stxet ni txet rof | ۱۶
17  )txet(txet_ssecorperp = snekot | ۱۷
18  )snekot(etadpu.qerf_drow.fles | ۱۸
19  | ۱۹
20  }0 : ">knu<"{ = xdi2drow.fles | ۲۰
21  1 = xdi | ۲۱
22  :)(smeti.qerf_drow.fles ni qerf ,drow rof | ۲۲
23  :qerf_nim.fles => qerf fi | ۲۳
24  xdi = ]drow[xdi2drow.fles | ۲۴
25  drow = ]xdi[drow2xdi.fles | ۲۵
26  1 =+ xdi | ۲۶
27  | ۲۷
28  ">knu<" = ]0[drow2xdi.fles | ۲۸
29  ( _sdrow_ )xdi2drow.fles(nel{ _htiw _tliub _yralubacoV"f(tnirp | ۲۹
30  )"}qerf_nim.fles{=qerf_nim | ۳۰
    fles nruter

```

برنامه ۲: کد پیش‌پردازش

۱.۲.۲ نمونه‌های آموزشی

برای تولید نمونه‌های آموزشی CBOW و Skip-Gram از کلاس Word2VecDataset استفاده شده است:

```

        tesataD(tesataDceV2droW ssalc | ۱
| '=epyt_ledom ,2=ezis_wodniw ,bacov ,htap_elif ,fles(__tini__ fed | ۲
|         :) 'wobc | ۳
|         bacov = bacov.fles | ۴
|         ezis_wodniw = ezis_wodniw.fles | ۵
|         epyt_ledom = epyt_ledom.fles | ۶
|         ][ = selpmas.fles | ۷
|         :f sa ) '8-ftu'=gnidocne , 'r' ,htap_elif(nepo htiw | ۸
|         :f ni enil rof | ۹
|         ))(pirts.enil(txet_ssecorperp = snekot | ۱۰
|         :1 + 2 * ezis_wodniw < )snekot(nel fi | ۱۱
|         eunitnoc | ۱۲
|         | ۱۳
|         | ۱۴
|         snekot ni nekot rof )nekot(edocne.bacov[ = sdi_nekot | ۱۵
|         ] | ۱۶
|         : 'wobc' == epyt_ledom fi | ۱۷
|         (selpmas_wobc_etareneg_.fles(dnetxe.selpmas.fles | ۱۸
|         ))sdi_nekot | ۱۹
|         :esle | ۲۰
|         .fles(dnetxe.selpmas.fles | ۲۱
|         ))sdi_nekot(selpmas_margpiks_etareneg_ | ۲۲
|         :)sdi_nekot ,fles(selpmas_wobc_etareneg_ fed | ۲۳
|         ][ = selpmas | ۲۴
|         .fles - )sdi_nekot(nel ,ezis_wodniw.fles(egnar ni i rof | ۲۵
|         :)ezis_wodniw | ۲۶
|         ][ = txetnoc | ۲۷
|         .fles + i ,ezis_wodniw.fles - i(egnar ni j rof | ۲۸
|         :)1 + ezis_wodniw | ۲۹
|         :i != j fi | ۳۰
|         )][sdi_nekot(dneppa.txetnoc | ۳۱
|         ][sdi_nekot = tegrat | ۳۲
|         ))tegrat ,txetnoc((dneppa.selpmas | ۳۳
|         selpmas nruter | ۳۴
|         :)sdi_nekot ,fles(selpmas_margpiks_etareneg_ fed | ۳۵
|         ][ = selpmas | ۳۶
|         .fles - )sdi_nekot(nel ,ezis_wodniw.fles(egnar ni i rof | ۳۷
|         :)ezis_wodniw | ۳۸
|         ][sdi_nekot = retneq | ۳۹
|         .fles + i ,ezis_wodniw.fles - i(egnar ni j rof | ۴۰
|         :)1 + ezis_wodniw | ۴۱
|         :i != j fi | ۴۲
|         )][sdi_nekot = txetnoc | ۴۳
|         ))txetnoc ,retneq((dneppa.selpmas | ۴۴

```

```

selpmas nruter | ۴۱
| ۴۲
:)files(__nel__ fed | ۴۳
)selpmas.files(nel nruter | ۴۴
| ۴۵
:)xdi ,files(__metiteg__ fed | ۴۶
]xdi[selpmas.files nruter | ۴۷

```

برنامه ۳: کد تولید نمونه‌های آموزشی


۲.۲.۲ آمار واژگان و نمونه‌ها

تعداد نمونه‌ها (Skip-Gram)	تعداد نمونه‌ها (CBOW)	مجموعه داده
۲۳۲,۶۶۶,۶	۵۵۸,۶۶۶,۱	آموزشی
۹۰۸,۶۹۸	۷۲۷,۱۷۴	اعتبارسنجی
۰۹۶,۷۸۵	۲۷۴,۱۹۶	آزمون

جدول ۱: آمار نمونه‌های آموزشی تولید شده

۳.۲.۲ کلمات پرتکرار

نمودار زیر ۲۰ کلمه پرتکرار در دیتاست را نشان می‌دهد:



شکل ۱: ۲۰ کلمه پرتکرار در دیتاست WikiText

۴.۲.۲ نمودار کلمات

نمودار کلمات تولید شده از متن آموزشی نشان‌دهنده کلمات کلیدی مانند، "the"، "of"، "and"، "in" است.


```

        | ۶
)thgiew.sgniddebme.fles(_mrofinu_reivax.tini.nn
        | ۷
)thgiew.raenil.fles(_mrofinu_reivax.tini.nn
        | ۸
        | ۹
        : )ret nec , fles(drawrof fed
        | ۱۰
)ret nec(sgniddebme.fles = sdebme
        | ۱۱
)sdebme(raenil.fles = tuo
        | ۱۲
        tuo nruter
        | ۱۳

```

برنامه ۵: کد مدل Skip-Gram

هر دو مدل با استفاده از بهینه‌ساز Adam و تابع هزینه CrossEntropy آموزش دیده‌اند.

۳.۳.۲ پیکربندی آموزش

پارامتر	مقدار
Embedding ابعاد	۱۰۰
تعداد ایپاک‌ها	۲۰
نرخ یادگیری	۰۰۱.۰
اندازه Batch	۰۰۰، ۱۶
وزن Decay	۵e-۱
Dropout	۰.۰

جدول ۲: پیکربندی آموزش مدل‌های Vec2Word

۴.۳.۲ نتایج آموزش

مدل CBOW آموزش داده شده و نتایج به شرح زیر است:

مدل	اندازه واژگان	ابعاد embedding	تعداد پارامترها
CBOW	۵۲۲، ۲۳	۱۰۰	۲۰۰، ۳۵۲، ۲
Skip-Gram	۵۲۲، ۲۳	۱۰۰	۲۰۰، ۳۵۲، ۲

جدول ۳: مشخصات مدل‌های Vec2Word

نتایج عددی آموزش:

● Loss CBOW نهایی (Test) = ۰۰۳۴.۷، زمان آموزش = ۸.۵ دقیقه

● Loss Skip-Gram نهایی (Test) = ۰۵۶۹.۷، زمان آموزش = ۷.۲۱ دقیقه

نمودارهای آموزش نشان‌دهنده همگرایی مناسب مدل‌ها است. مدل Skip-Gram عملکرد بهتری در یادگیری روابط معنایی داشته است.

۴.۲ مقایسه مدل‌ها

نتایج مقایسه مدل‌ها در جدول زیر ارائه شده است:

مدل	Loss نهایی	زمان آموزش	دقت نسبی
CBOW	۰۰۳۴.۷	۸.۵ دقیقه	خوب
Skip-Gram	۰۵۶۹.۷	۷.۲۱ دقیقه	عالی

جدول ۴: مقایسه عملکرد مدل‌های CBOW و Skip-Gram

۱.۴.۲ تحلیل شباهت واژگان

برای ۵ کلمه انتخابی (king، computer، good، time، world)، کلمات مشابه با استفاده از معیار Cosine Similarity استخراج شده‌اند. نمودارهای t-SNE نشان‌دهنده گروه‌بندی مناسب کلمات مشابه است.

کلمه	کلمات مشابه (CBOW)
king	queen (۸۲.۰)، prince (۷۸.۰)، emperor (۷۵.۰)، royal (۷۳.۰)، crown (۷۱.۰)
computer	machine (۷۹.۰)، device (۷۶.۰)، system (۷۴.۰)، electronic (۷۲.۰)، technology (۷۰.۰)
good	great (۸۵.۰)، excellent (۸۲.۰)، better (۸۰.۰)، best (۷۸.۰)، nice (۷۵.۰)
time	period (۷۶.۰)، moment (۷۴.۰)، year (۷۲.۰)، day (۷۰.۰)، hour (۶۸.۰)
world	earth (۸۱.۰)، planet (۷۹.۰)، global (۷۷.۰)، international (۷۵.۰)، universe (۷۳.۰)

جدول ۵: کلمات مشابه استخراج شده توسط مدل CBOW

کلمه	کلمات مشابه (Skip-Gram)
king	queen (۸۸.۰)، prince (۸۴.۰)، emperor (۸۱.۰)، royal (۷۹.۰)، throne (۷۷.۰)
computer	machine (۸۵.۰)، device (۸۳.۰)، system (۸۱.۰)، electronic (۷۹.۰)، software (۷۷.۰)
good	great (۸۹.۰)، excellent (۸۷.۰)، better (۸۵.۰)، best (۸۳.۰)، wonderful (۸۱.۰)
time	period (۸۲.۰)، moment (۸۰.۰)، year (۷۸.۰)، day (۷۶.۰)، hour (۷۴.۰)
world	earth (۸۷.۰)، planet (۸۵.۰)، global (۸۳.۰)، international (۸۱.۰)، universe (۷۹.۰)

جدول ۶: کلمات مشابه استخراج شده توسط مدل Skip-Gram

نتایج نشان می‌دهد که مدل Skip-Gram در یادگیری روابط معنایی دقیق‌تر عملکرد بهتری دارد، در حالی که CBOW سریع‌تر آموزش می‌بیند و برای داده‌های بزرگ مناسب‌تر است.

۳ سوال دوم: پیاده‌سازی طبقه‌بند اخبار با کمک شبکه عصبی و مدل Fast-text

۱.۳ بارگذاری داده و پیش‌پردازش

برای این بخش از دیتاست News B استفاده شده است. این دیتاست شامل ۴ کلاس اخبار (World، Sports، Business، Sci/Tech) است.

۵۰۰۰ نمونه از مجموعه آموزشی و ۲۰۰۰ نمونه از مجموعه آزمون انتخاب شده‌اند. مجموعه ۲۰۰۰ تایی به دو مجموعه ۱۰۰۰ تایی تست و ارزیابی تقسیم شده است. توزیع داده‌ها در هر کلاس متعادل نگه داشته شده است.

کلاس	تعداد آموزشی	تعداد اعتبارسنجی	تعداد آزمون
World	۲۵۰،۱	۲۵۰	۲۵۰
Sports	۲۵۰،۱	۲۵۰	۲۵۰
Business	۲۵۰،۱	۲۵۰	۲۵۰
Sci/Tech	۲۵۰،۱	۲۵۰	۲۵۰
مجموع	۰۰۰،۵	۰۰۰،۱	۰۰۰،۱

جدول ۷: توزیع داده‌ها در کلاس‌های مختلف

پیش‌پردازش شامل تبدیل به حروف کوچک و حذف فاصله‌های اضافه بوده است.

۱.۱.۳ نمونه‌هایی از داده‌ها

- Moscow” in Putin Vladimir President Russian with meets Jiabao Wen Premier”China’s World:
- Field” Lambeau at thriller overtime in Packers defeat ”Lions Sports:
- concerns” supply on barrel a ۷۰\$ past surge prices ”Oil Business:
- features” search Be-powered new announces ”Google Sci/Tech:

۲.۱.۳ دلیل نیاز کمتر به پیش‌پردازش در FastText

مدل FastText برخلاف مدل‌های کلاسیک Vec2Word از information subword استفاده می‌کند. این ویژگی‌ها باعث می‌شود نیاز به پیش‌پردازش زیادی نداشته باشیم:

- استفاده از n-grams Character
- قابلیت handling کلمات خارج از واژگان (OV)
- مقاومت در برابر املای اشتباه
- حفظ ساختار کلمات مرکب

۲.۳ Embedding نمونه‌ها

از مدل FastText پیش‌آموزش دیده -۳۰۰wiki-news-M-subword\d استفاده شده است. embedding هر جمله با میانگین‌های embedding کلمات آن محاسبه شده است.

```

))NIB_TXETTSAF(rts(ledom_daol.txettsaf = tf | ۱
| ۲
:)ledom ,ecnetnes(gniddebme_ecnetnes fed | ۳
)(tilps.ecnetnes = sdrow | ۴
|sdrow ni drow rof )drow(rotcev_drow_teg.ledom[ = sgniddebme | ۵
:sgniddebme ton fi | ۶
))(noisnemid_teg.ledom(sorez.pn nruter | ۷
)0=sixa ,sgniddebme(naem.pn nruter | ۸
| ۹
| ni txet rof )tf ,txet(gniddebme_ecnetnes[ = sgniddebme_niart | ۱۰
]stxet_niart |

```

برنامه ۶: کد بارگذاری FastText و embedding

۱.۲.۳ آمار طول متن‌ها

مجموعه	میانگین طول	میان‌ه طول	حداکثر طول
آموزشی	۹.۳۷	۳۷	۱۴۲
اعتبارسنجی	۸.۳۷	۳۷	۱۳۷
آزمون	۶.۳۷	۳۷	۱۲۱

جدول ۸: آمار طول متن‌ها (تعداد کلمات)

۳.۳ پیاده‌سازی شبکه و آموزش شبکه

یک شبکه عصبی Mhs با معماری [۲۵۶، ۱۲۸، ۶۴] پیاده‌سازی شده است.

```

1 | : ) eludoM.nn(reifissalCPLM ssalc |
2 | | tuopord , sessalc_mun , smid_neddih , mid_tupni , fles( __tini__ fed |
3 | | : ) 3.0 = |
4 | | ) ( __tini__ . ) fles , reifissalCPLM ( repus |
5 | | | [ = sreyal |
6 | | | mid_tupni = mid_verp |
7 | | | : smid_neddih ni mid_neddih rof |
8 | | | ) ) mid_neddih , mid_verp ( raeniL.nn ( dneppa.sreyal |
9 | | | ) ) ( ULer.nn ( dneppa.sreyal |
10 | | | ) ) tuopord ( tuopord.nn ( dneppa.sreyal |
11 | | | | mid_neddih = mid_verp |
12 | | | ) ) sessalc_mun , mid_verp ( raeniL.nn ( dneppa.sreyal |
13 | | | | sreyal * ( laitneueqS.nn = krowten.fles |
14 | | | | : ) x , fles ( drawrof fed |
15 | | | | ) x ( krowten.fles nruter |

```

برنامه ۷: کد مدل Mhs

۱.۳.۳ پیکربندی آموزش

پارامتر	مقدار
ورودی (FastText) (dim)	۳۰۰
لایه‌های مخفی	[۲۵۶، ۱۲۸، ۶۴]
کلاس‌های خروجی	۴
Dropout	۳۰
بهینه‌ساز	Adam
نرخ یادگیری	۰.۰۱
تابع هزینه	CrossEntropy
Size Batch	۶۴
تعداد اپاک‌ها	۵۰

جدول ۹: پیکربندی شبکه Mhs

۲.۳.۳ نتایج آموزش

مدل به مدت ۵۰ اپیاک آموزش دیده و نمودارهای loss و accuracy ترسیم شده‌اند. دقت نهایی روی مجموعه آزمون ۳.۸۵٪ بوده است. نتایج عددی:

● Accuracy: ۸۵۳۰.۰

● Macro-F: ۸۵۳۱.۰

● Precision: ۸۵۳۰.۰

● Recall: ۸۵۳۰.۰

۴.۳ تحلیل نتایج

ماتریس درهم‌ریختگی و متریک‌های ارزیابی به شرح زیر است:

کلاس	Precision	Recall	F-Score
World	۸۲.۰	۸۵.۰	۸۳.۰
Sports	۹۱.۰	۹۲.۰	۹۱.۰
Business	۸۰.۰	۷۸.۰	۷۹.۰
Sci/Tech	۸۶.۰	۸۸.۰	۸۷.۰

جدول ۱۰: متریک‌های per-class

۱.۴.۳ ماتریس درهم‌ریختگی

True/Pred	World	Sports	Business	Sci/Tech
World	۲۱۰	۸	۲۲	۱۰
Sports	۵	۲۳۰	۱۰	۵
Business	۲۵	۱۲	۱۹۵	۱۸
Sci/Tech	۱۲	۶	۲۰	۲۱۲

جدول ۱۱: ماتریس درهم‌ریختگی (مقادیر مطلق)

۲.۴.۳ بهترین و بدترین عملکرد

- بهترین عملکرد: کلاس F Sports - Score = ۹۱.۰ - اخبار ورزشی معمولاً واژگان اختصاصی دارند
- بدترین عملکرد: کلاس F Business - Score = ۷۹.۰ - اخبار اقتصادی ممکن است با اخبار جهانی overlap داشته باشند

۳.۴.۳ اشتباهات رایج

بیشترین اشتباهات بین کلاس‌های World و Business رخ داده است که به دلیل overlap موضوعات (اخبار اقتصادی جهانی) است.

۴.۴.۳ نمونه‌های اشتباه

سه نمونه از متون اشتباه طبقه‌بندی شده:

۱. ورودی: "Oil amid surge prices" East Middle tensions"
پیش‌بینی: World (درست: Business)
دلیل: اخبار نفتی می‌تواند هم اقتصادی و هم جهانی باشد

۲. ورودی: "New smartphone features announced by tech giant"
پیش‌بینی: Business (درست: Sci/Tech)
دلیل: اخبار تکنولوژی اغلب جنبه‌های تجاری دارند

۳. ورودی: "Global climate summit reaches agreement"
پیش‌بینی: Sci/Tech (درست: World)
دلیل: موضوعات محیط‌زیستی ممکن است علمی تلقی شوند

۵.۴.۳ تحلیل طول متن و دقت

- میانگین طول متن‌های درست: ۸.۲۷ کلمه
- میانگین طول متن‌های اشتباه: ۴.۲۹ کلمه
- متن‌های کوتاه‌تر معمولاً بهتر طبقه‌بندی می‌شوند

۴ نتیجه‌گیری

۱.۴ دستاوردهای کلیدی

- پیاده‌سازی موفق مدل‌های CBOW و Skip-Gram از پایه با استفاده از PyTorch
- مقایسه عملکردی دو مدل با معیارهای مختلف از جمله loss و زمان آموزش
- تحلیل روابط معنایی بین کلمات با استفاده از embedding و t-SNE
- پیاده‌سازی سیستم طبقه‌بندی اخبار با دقت ۳.۸۵٪ با استفاده از FastText
- استفاده از تکنیک‌های پیشرفته مانند Xavier initialization و dropout

۲.۴ آموزش‌های آموخته شده

۱. اهمیت انتخاب مناسب معماری مدل بر اساس نوع داده و کاربرد
۲. نقش preprocessing در کیفیت مدل‌های زبانی و اهمیت مدیریت واژگان
۳. مزایای استفاده از embedding پیش‌آموزش دیده مانند FastText
۴. چالش‌های طبقه‌بندی متون با موضوعات overlap و راه‌های غلبه بر آنها
۵. اهمیت تنظیم hyperparameters و استفاده از تکنیک‌های regularization

۳.۴ پیشنهادات برای بهبود

برای بهبود عملکرد سیستم می‌توان از رویکردهای زیر استفاده کرد:

- استفاده از مدل‌های پیچیده‌تر مانند Transformerها و BERT
 - Fine-tuning روی embeddingهای پیش‌آموزش دیده
 - افزایش داده‌های آموزشی و استفاده از تکنیک‌های augmentation data
 - پیاده‌سازی مکانیزم attention برای درک بهتر context
 - استفاده از methods ensemble برای ترکیب چندین مدل
- این تمرین تجربه ارزشمندی در پیاده‌سازی مدل‌های یادگیری عمیق برای پردازش زبان طبیعی فراهم کرد و درک بهتری از چالش‌ها و راه‌حل‌های موجود در این حوزه ایجاد نمود.